

Analisi dei Dati con Modello di Random Forest

Nome del Progetto: *Predictive Maintenance per Sensori*

March 15, 2025

Obiettivi del Progetto

L'obiettivo di questo progetto è quello di analizzare i dati provenienti da sensori di macchine per prevedere il loro stato di salute e prevenire guasti. Le fasi principali del progetto includono:

- ▶ Caricamento e validazione dei dati da file CSV
- ▶ Preprocessing dei dati con gestione dei valori mancanti e degli outliers
- ▶ Addestramento di un modello RandomForest per la previsione dello stato delle macchine
- ▶ Applicazione di SMOTE per bilanciare le classi
- ▶ Valutazione del modello con metodi come la matrice di confusione, l'importanza delle feature e la cross-validation

Caricamento e Preprocessing dei Dati

- ▶ Il progetto carica e valida i dati provenienti da sensori delle macchine, gestendo valori mancanti e duplicati.
- ▶ I dati vengono preprocessati con:
 - ▶ Conversione dei timestamp in variabili temporali come ora, giorno, mese, anno
 - ▶ Normalizzazione delle caratteristiche tramite StandardScaler
 - ▶ Gestione dei valori mancanti con la sostituzione dei NaN con la mediana
 - ▶ Gestione degli outliers tramite il calcolo dell'IQR

Training del Modello

Il modello di machine learning utilizzato è un Random Forest Classifier, che viene addestrato sui dati preprocessati. Durante l'addestramento, viene applicata la tecnica SMOTE per bilanciare le classi, in modo da evitare squilibri che potrebbero influire negativamente sulla performance del modello.

- ▶ SMOTE è utilizzato per generare esempi sintetici della classe minoritaria.
- ▶ Il modello viene salvato per utilizzi futuri.

Valutazione del Modello

La valutazione del modello viene effettuata utilizzando i seguenti metodi:

- ▶ **Matrice di Confusione:** per visualizzare le prestazioni del modello in termini di classificazione corretta e errata.
- ▶ **Importanza delle Feature:** per capire quali caratteristiche influenzano maggiormente le previsioni del modello.
- ▶ **Cross-Validation:** per valutare la stabilità del modello attraverso diverse suddivisioni dei dati.

I seguenti grafici sono utilizzati per visualizzare i risultati:

Grafico dell'Importanza delle Feature




Figure: Grafico che mostra l'importanza delle varie feature nel modello Random Forest. Le features più importanti sono quelle che contribuiscono maggiormente alla decisione finale del modello. Questa visualizzazione aiuta a comprendere quali sensori o variabili hanno un impatto maggiore sulla previsione dello stato della macchina.

Matrice di Confusione




Figure: Matrice di confusione che mostra i risultati della classificazione. Ogni cella rappresenta il numero di istanze appartenenti a una determinata classe predetta rispetto alla classe reale. Una diagonale più lunga indica un buon comportamento del modello.

Cross-Validation




Figure: Risultati della cross-validation del modello. Questo grafico mostra la distribuzione dei punteggi di accuratezza su diversi fold. La media di accuratezza tra i vari fold è alta, indicando che il modello è stabile e generalizza bene su diverse suddivisioni dei dati. La leggera variazione tra i fold suggerisce che il modello non è eccessivamente sensibile ai dati di addestramento.

Conclusioni

In sintesi, il modello sviluppato ha raggiunto ottime performance con una precisione e recall molto alti su tutte le classi.